

MAT02053

Estatística Aplicada a Negócios

Prof. Renan Xavier Cortes

Introdução teórica da Estatística no mundo dos negócios

Cronograma

- **Conceitos Comuns no mundo dos negócios**
 - **Papéis e Profissionais da Área de Dados**
 - **Cientistas**
 - **Analistas**
 - **Engenheiros**
 - **etc.**
 - **Conceitos Tecnológicos**
 - **Jargões de negócio**
- **Considerações Mercado vs. Academia**

Papéis e Profissionais da Área de Dados

Qual a diferença entre os papéis e profissionais da área de dados?


Mas antes, vamos dar um contexto histórico...

Papéis e Profissionais da Área de Dados



“the sexiest job in the next 10 years will be statisticians.” – Varian, Hal (2009). Economista-chefe do Google de 2002 até agosto 2025 (aposentou).

Papéis e Profissionais da Área de Dados



“Statistics is now the sexiest job around” – Rosling, Hans. Documentário da BBC em 2011.

Papéis e Profissionais da Área de Dados



Outubro de 2012

Thomas H. Davenport e D.J. Patil

Data Scientist: The Sexiest Job of the 21st Century

“Cientistas de Dados hoje são como os quants de Wall Street nas décadas de 80 e 90.”

Papéis e Profissionais da Área de Dados

MATH & STATISTICS

- ☆ Machine learning
- ☆ Statistical modeling
- ☆ Experiment design
- ☆ Bayesian inference
- ☆ Supervised learning: decision trees, random forests, logistic regression
- ☆ Unsupervised learning: clustering, dimensionality reduction
- ☆ Optimization: gradient descent and variants

DOMAIN KNOWLEDGE & SOFT SKILLS

- ☆ Passionate about the business
- ☆ Curious about data
- ☆ Influence without authority
- ☆ Hacker mindset
- ☆ Problem solver
- ☆ Strategic, proactive, creative, innovative and collaborative

PROGRAMMING & DATABASE


- ☆ Computer science fundamentals
- ☆ Scripting language e.g. Python
- ☆ Statistical computing package e.g. R
- ☆ Databases SQL and NoSQL
- ☆ Relational algebra
- ☆ Parallel databases and parallel query processing
- ☆ MapReduce concepts
- ☆ Hadoop and Hive/Pig
- ☆ Custom reducers
- ☆ Experience with xaaS like AWS

COMMUNICATION & VISUALIZATION

- ☆ Able to engage with senior management
- ☆ Story telling skills
- ☆ Translate data-driven insights into decisions and actions
- ☆ Visual art design
- ☆ R packages like ggplot or lattice
- ☆ Knowledge of any of visualization tools e.g. Flare, D3.js, Tableau



Papéis e Profissionais da Área de Dados



Papéis e Profissionais da Área de Dados


Mas... Existe esse profissional no Mercado?



"Não existe espaço para heroísmo em Data Science" – Crepalde, Neylson (2020). Data Scientist e Sr. Generative AI Strategist @ AWS | PhD

Papéis e Profissionais da Área de Dados

E... As empresas sabem como procurar?



Sebastián Ramírez
@tiangolo

...

I saw a job post the other day. 📌

It required 4+ years of experience in FastAPI. 🤖

I couldn't apply as I only have 1.5+ years of experience since I created that thing. 😅

Maybe it's time to re-evaluate that "years of experience = skill level". ♻️

[Traduzir Tweet](#)

10:40 AM · 11 de jul de 2020 · Twitter Web App

45,3 mil Retweets 3 mil Tweets de comentário 178,2 mil Curtidas

Papéis e Profissionais da Área de Dados

DIFERENÇA ENTRE PROFISSIONAIS DE DADOS E SOFTWARE

CIENTISTA DE DADOS (Data Scientist)

Foco: Futuro & Previsão

Atividades Chave



Desenvolvimento
de Modelos



Formular Novas
Perguntas

Technologies:

Python, R, Spark, TensorFlow, Big Data



Papéis e Profissionais da Área de Dados



Papéis e Profissionais da Área de Dados

DIFERENÇA ENTRE PROFISSIONAIS DE DADOS E SOFTWARE

CIENTISTA DE DADOS (Data Scientist)

Foco: Futuro & Previsão

Atividades Chave



Technologies:

Python, R, Spark, TensorFlow, Big Data

ANALISTA DE DADOS (Data Analyst)

Foco: Passado & Presente

Atividades Chave



Technologies:

SQL, Excel, Tableau, Power BI, Python

ENGENHEIRO DE DADOS Foco: Arquitetura & Infraestrutura de Dados

Atividades Chave



Technologies:

SQL, Spark, Airflow, Hadoop, Kafka, Python

TODOS TRABALHAMOS COM DADOS PARA GERAR INSIGHTS

Papéis e Profissionais da Área de Dados

DIFERENÇA ENTRE PROFISSIONAIS DE DADOS E SOFTWARE

CIENTISTA DE DADOS (Data Scientist)

Foco: Futuro & Previsão

Atividades Chave



Technologies:

Python, R, Spark, TensorFlow, Big Data

ANALISTA DE DADOS (Data Analyst)

Foco: Passado & Presente

Atividades Chave



Technologies:

SQL, Excel, Tableau, Power BI, Python

ENGENHEIRO DE DADOS Foco: Arquitetura & Infraestrutura de Dados

Atividades Chave



Technologies:

SQL, Spark, Airflow, Hadoop, Kafka, Python

TODOS TRABALHAM
COM DADOS E SISTEMAS
PARA GERAR VALOR

ENGENHEIRO DE SOFTWARE Foco: Aplicações & Integração do Sistema

Atividades Chave



Technologies:

APIs (REST, GraphQL), Kafka, MongoDB, Java, Docker, Python

Papéis e Profissionais da Área de Dados

- Evidentemente que existe muita intersecção entre áreas.
- Eventualmente, por exemplo, um Cientista de Dados pode desempenhar o papel (fala-se muito em “usar o chapéu”) de um Engenheiro de Dados, ou vice-versa.
- No entanto, é importante ter estas distinções claras para saber qual a responsabilidade “principal” de cada profissional envolvido.

Papéis e Profissionais da Área de Dados

➤ Outros termos também aparecem no mundo dos negócios como Analistas de BI, Analistas de Negócios, etc.

➤ O termo Business Intelligence (BI) de acordo com o site da IBM:

“Business intelligence (BI) is a set of technological processes for collecting, managing and analyzing organizational data to yield insights that inform business strategies and operations. Business intelligence analysts transform raw data into meaningful insights that drive strategic decision-making within an organization.”

Note que BI tem mais relação com a pergunta “O que aconteceu?” do que com a pergunta “O que vai acontecer?”. Logo, tem mais relação com Analistas de Dados.

Papéis e Profissionais da Área de Dados

- Mais recentemente, outros termos aparecem também como Data Steward , Engenheiro de IA , Engenheiro de ML, Engenheiro de Prompt, Engenheiro de Analytics, MLOps, DevOps, FinOps, etc., etc.
- Enfim, o mundo dos negócios é muito criativo em ficar dando nomes pras coisas, criando hypes, etc.

Papéis e Profissionais da Área de Dados



Tente não surtar...

O VASTO ECOSSISTEMA DE CARREIRAS EM DADOS E IA

ANÁLISE DE DADOS & NEGÓCIOS

- Analista de Dados
- Analista de Negócios
- Analista de BI
- Desenvolvedor de BI
- Engenheiro de Analytics
- Analista de Produto
- Analista de Marketing
- Analista Financeiro
- Analista de Operações
- Analista de Insights do Consumidor
- Analista de Risco
- Cientista de Decisão
- Analista Quantitativo (Quant)

CIÊNCIA DE DADOS & IA

- Cientista de Dados
- Cientista de Dados Aplicados
- Engenheiro de Machine Learning
- Engenheiro de IA
- Engenheiro de Prompt
- Engenheiro de IA Generativa
- Arquiteto de Soluções de IA
- Engenheiro de Pesquisa de IA
- Cientista de Pesquisa de IA
- Engenheiro de Visão Computacional
- Engenheiro de NLP
- Engenheiro de Sistemas de Recomendação
- Engenheiro de Reinforcement Learning
- Engenheiro de Deep Learning
- Engenheiro de IA Responsável
- Engenheiro de Avaliação de IA (Avaliador de LLM)

ENGENHARIA DE DADOS

- Engenheiro de Dados
- Engenheiro de Analytics
- Desenvolvedor ETL
- Desenvolvedor ELT
- Engenheiro Big Data
- Engenheiro de Plataforma de Dados
- Engenheiro de Streaming de Dados
- Engenheiro de Infraestrutura de Dados
- Engenheiro de Nuvem de Dados
- Engenheiro de Banco de Dados
- Engenheiro de Integração de Dados

GESTÃO & GOVERNANÇA DE DADOS

- Data Steward
- Analista de Governança de Dados
- Gerente de Governança de Dados
- Analista de Qualidade de Dados
- Engenheiro de Qualidade de Dados
- Especialista MDM (Master Data Management)
- Especialista em Metadados
- Gerente de Catálogo de Dados
- Especialista em Governança de Informação
- Analista de Privacidade de Dados
- Oficial de Conformidade de Dados

OPERAÇÕES DE MACHINE LEARNING (MLOps)

- Engenheiro MLOps
- Engenheiro LLMops
- Engenheiro de Operações de Modelos
- Engenheiro de Plataforma de IA
- Engenheiro Feature Store
- Engenheiro de Validação de Modelos
- Engenheiro de Infraestrutura de ML
- Engenheiro de Plataforma de ML

SOFTWARE & INFRAESTRUTURA

- Engenheiro DevOps
- Engenheiro de Plataforma
- Engenheiro SRE (Site Reliability Engineer)
- Engenheiro de Nuvem
- Arquiteto de Nuvem
- Arquiteto de Soluções
- Engenheiro Backend (Plataformas de Dados)
- Engenheiro de Infraestrutura

ARQUITETURA DE DADOS

- Arquiteto de Dados
- Arquiteto de Dados Enterprise
- Arquiteto de Dados de Nuvem
- Arquiteto de Solução
- Arquiteto de Informação

FUNÇÕES DE BANCO DE DADOS

- Administrador de Banco de Dados (DBA)
- Desenvolvedor de Banco de Dados
- Arquiteto de Banco de Dados
- Desenvolvedor SQL
- Engenheiro NoSQL

VISUALIZAÇÃO DE DADOS & BI

- Engenheiro FinOps
- Analista FinOps
- Analista de Custo de Nuvem
- Analista Financeiro de Nuvem

VISUALIZAÇÃO DE DADOS & BI

- Desenvolvedor de BI
- Desenvolvedor Tableau
- Desenvolvedor Power BI
- Especialista em Visualização de Dados
- Desenvolvedor de Dashboards
- Analista de Relatórios

SEGURANÇA & PRIVACIDADE DE DADOS

- Engenheiro de Segurança de Dados
- Engenheiro de Privacidade de Dados
- Encarregado de Dados (DPO)
- Analista de Segurança da Informação
- Analista de Dados de Cibersegurança

FINANÇAS & OTIMIZAÇÃO DE CUSTOS (FINOPS)

- Engenheiro FinOps
- Analista FinOps
- Analista de Custo de Nuvem
- Analista Financeiro de Nuvem

Que tipo de tecnologia é utilizada
no mundo dos negócios?

Conceitos Tecnológicos

- Big Data
- Data Lake
- Computação em Nuvem
- ETL
- SQL
- Spark
- Dashboards
- Machine Learning
- Implantação/Deploy
- LLM
- GenAI

Data vs. Big Data

- Big Data: *“estudo e aplicações de dados que são muito complexos para software de processamento de dados tradicionais”* (Wikipedia).
- Será que precisamos de novas ferramentas para lidar com esse novo cenário?

SCIENCE / US & WORLD / TECH

Excel spreadsheet error blamed for UK's 16,000 missing coronavirus cases

The case went missing after the spreadsheet hit its filesize limit

By James Vincent | Oct 5, 2020, 9:41am EDT

Fonte: <https://www.theverge.com/2020/10/5/21502141/uk-missing-coronavirus-cases-excel-spreadsheet-error>

Data vs. Big Data

➤ Os 3 V's (ou 5) do Big Data:

➤ Volume

➤ Velocidade

➤ Variedade

➤ Valor


➤ Veracidade

➤ Qual a infraestrutura para lidar com essa quantidade de dados?

➤ Novo paradoxo:



Data vs. Big Data



➤ Lembre-se de que “*não existe heroísmo em Data Science*”.

Data Lake

- Segundo a Google: *“Um data lake é um repositório centralizado, escalonável e seguro projetado para armazenar, processar e analisar grandes quantidades de dados estruturados, semiestruturados e não estruturados no formato nativo.”*
- Na prática, é um conjunto de tabelas mais genérico que abrange uma grande possibilidade/variedade de tipos de dados sem uma estrutura de “conexão” entre as tabelas bem definidas.

Data Lake

- Quem mantém a “qualidade” de um Data Lake são, em geral, Engenheiros de Dados.
- Você interage com Data Lakes de maneira “remota”. Isto é, você não trabalha localmente com um Data Lake, mas sim com uma interface pois ele fica na nuvem.
- Interação com os dados são feitas com frameworks que rodam em “clusters” de computadores devido à quantidade massiva de dados.

Computação em Nuvem

- **Computação em Nuvem (*Cloud Computing*)**, segundo a Amazon é: *“...a entrega de recursos de TI sob demanda por meio da Internet com preço conforme o uso. Em vez de comprar, ter e manter data centers e servidores físicos, você pode acessar serviços de tecnologia, como capacidade computacional, armazenamento e bancos de dados, conforme a necessidade, usando um provedor de nuvem...”*

- **Trabalhar “na Nuvem”** é o oposto de trabalhar “localmente”.



Datacenter do Facebook no Ártico

ETL

➤ ETL é a sigla para *Extract, Transform and Load*



Fonte: <https://wiki.databurst.tech/docs/roadmap/data-integration/etl/>


ETL

- Por mais que esse conceito de ETL esteja mais presente em processos de Pipelines de Engenharia, essa “lógica” de trabalhar com dados está no dia-a-dia de basicamente qualquer profissional de dados (Cientistas, Analistas, etc.)
- Lembre-se: você praticamente NUNCA vai receber uma base pronta para um (a) modelo/análise para trabalhar



ETL

- Esse conceito de “níveis de qualidade” de um dado está bastante presente nas tabelas disponibilizadas para os times de dados. Por exemplo, é comum um Data Lake apresentar “camadas”.



Fonte: <https://piethein.medium.com/medallion-architecture-best-practices-for-managing-bronze-silver-and-gold-486de7c90055>

SQL

- SQL é a sigla para *Structured Query Language*
- Se pronuncia “éssiqueéle” ou até mesmo é possível “siquou”
- É a linguagem mais “padrão” para se interagir com bases de dados tanto em Datawarehouse (relacionais) ou não-relacionais (como Data Lakes)

SQL

- SQL não é a única maneira de interagir com esses dados, mas é o framework mais utilizado.
- Existem diferentes maneiras de “executar” a linguagem SQL em diferentes programas como MySQL, PostGres, Microsoft SQL Server, Oracle, etc.
- Exemplos de Funções: SELECT, FROM, INNER JOIN, WHERE

Spark

- Framework usado para dados distribuídos e processados em clusters de computadores.
- “*Apache Spark is an [open-source](#) unified analytics engine for large-scale data processing. Spark provides an [interface](#) for programming clusters with implicit [data parallelism](#) and [fault tolerance](#). Originally developed at the [University of California, Berkeley](#)'s [AMPLab](#) starting in 2009...*”



- PySpark, sparklyr, SparkSQL




Fonte: https://en.wikipedia.org/wiki/Apache_Spark

Dashboards

- “Um dashboard é uma interface visual que reúne métricas principais, (...) e visualizações de dados de uma ou mais fontes em uma única tela” (Databricks)




Machine Learning




Machine Learning

➤ O aprendizado de máquina (ML) é um subcampo da inteligência artificial no qual os computadores aprendem a partir de dados e identificam padrões.

➤ Em geral, pode ser um aprendizado supervisionado ou não-supervisionado.



Machine Learning



Unsupervised Learning


Aim to discover structure:
no target variable known



Supervised Learning

Aim to predict or model a
known target

Machine Learning



Unsupervised Learning

Aim to discover structure:
no target variable known



Supervised Learning

Aim to predict or model a
known target



Reinforcement Learning

Optimise actions in a way that
maximises cumulative reward

Machine Learning — Alguns dos Principais algoritmos


Supervisionado

- **Classificação**
 - **Regressão Logística**
 - **Support Vector Machines**
- **Regressão**
 - **Regressão Linear**
 - **Regressão Ridge/Lasso**
- **Modelos Baseados em Árvore**
- ***K- Nearest Neighbors***


Não-Supervisionado

- **Análise de Componentes Principais**
- **Análise de Cluster**
 - **K-Means**
 - **Hierárquico**
- **Escalonamento Multidimensional**


Overfitting e Underfitting: Motivação



Underfitted



Good Fit/Robust




Overfitted




Overfitting e Underfitting: Estratégias de Validação

➤ Holdout set simples



➤ K-Fold Cross-Validation



Overfitting e Underfitting: Estratégias de Validação

- Se estamos em um cenário com muitos dados. Podemos “nos dar ao luxo” de criar também uma amostra de validação apartada da de teste.




- Discussões Interessantes: <https://machinelearningmastery.com/train-final-machine-learning-model/> e <https://stats.stackexchange.com/questions/52274/how-to-choose-a-predictive-model-after-k-fold-cross-validation>
- Blog Post: [Alguns pensamentos teóricos e aleatórios com relação à Machine Learning \(sem código, sem matemática e sem papas na língua\)](#)

Fonte: Friedman, Jerome, Trevor Hastie, and Robert Tibshirani. *The elements of statistical learning*. Vol. 1. No. 10. New York: Springer series in statistics, 2001.

Implantação/Deploy

- O modelo de Machine Learning não tem muita utilidade pro negócio se ele não for colocado em Produção!
- “Colocar em Produção” significa “expor” o modelo para fazer previsões/inferências/decisões em dados reais que irão impactar o negócio.
- É uma parte **extremamente crítica** do processo de Ciência de Dados.

Implantação/Deploy



Implantação/Deploy

- Em geral, essa exposição pode ser de duas maneiras:

Em batch/Assíncrona

Dados preditos já calculados e só serão acessados em uma base

X

Online/Real-Time/Síncrona

Dados preditos serão calculados pelo modelo (exposto em uma API) em tempo real


- Vai depender da natureza do problema e de como os stakeholders (vulgo: “pessoas interessadas nesse modelo funcionando”) vão interagir com/analisar o modelo

Implantação/Deploy

DUAS MANEIRAS DE EXPOR UM MODELO DE MACHINE LEARNING: LOTE VS. TEMPO REAL


MÉTODO 1: PROCESSAMENTO EM LOTE & ASSÍNCRONO (BATCH)

Exportação de Dados "Já Preditos"



MÉTODO 2: PROCESSAMENTO EM TEMPO REAL & SÍNCRONO (REAL-TIME)

Exposição Via API com Dados "A Serem Preditos"



Implantação/Deploy

- Nessa etapa, em geral, profissionais de MLOps (em geral, cientistas de dados ou engenheiros de software) auxiliam nesse processo.

Assistir a pergunta que este rapaz faz
no segundo 37:55 desse vídeo:

<https://www.youtube.com/watch?v=Lvt3hFQUhHY&t=6s>



Minha Experiência como Cientista de Dados no Mercado

Implantação/Deploy

- Nessa etapa, muitos detalhes devem ser levados em consideração como a maneira que os dados estão estruturados para o processo de inferência (isto é, “fazer o predict”).
- Após um modelo estar em produção, é importante monitorar a qualidade dele e fazer perguntas como:
 - As previsões estão estáveis?
 - Os dados de entrada estão estáveis ou tem “data drift”?
 - A estrutura que sustenta o modelo está disponível e tempestiva?

Implantação/Deploy



➤ Um dos frameworks mais utilizados é o MLFlow

The screenshot shows the MLflow web interface. At the top, the experiment name is 'PROPENSAO_AQUISICAO_CARTAO_CREDITO' with a filter 'Machine learning'. Below the header, there are tabs for 'Runs', 'Models', and 'Traces'. The 'Runs' tab is active, displaying a table of runs. The table has columns for Run Name, Created, Dataset, Duration, Source, and Models. The runs are listed in descending order of creation time. The first run is 'nimble-sponge-875' created 1 month ago. The last run is 'nosy-penguin-34' created 6 months ago. The table is filtered by 'metrics.rmse < 1 and params.model = "tree"'. The table has 74 columns in total, with 7 columns visible. A 'Show more columns (74 total)' button is visible on the right side of the table.

	Run Name	Created	Dataset	Duration	Source	Models
☐	nimble-sponge-875	1 month ago	-	1.9h	run 7889...	sicredi_cas.exp_nba... +1
☐	enchanted-gull-444	1 month ago	-	15.3h	run 7262...	sicredi_cas.exp_nba... +1
☐	shivering-newt-376	2 months ago	-	52.5d	run 6605...	sicredi_cas.exp_nba... +1
☐	classy-cat-80	3 months ago	-	22.0h	run 2439...	sicredi_cas.exp_nba... +1
☐	resilient-stoat-480	5 months ago	-	6.4d	run 8094...	sicredi_cas.exp_nba... +1
☐	nervous-fox-216	5 months ago	-	16.6h	run 2127...	sicredi_cas.exp_nba... +1
☐	agreeable-crow-280	6 months ago	-	2.0d	run 5405...	sicredi_cas.exp_nba... +1
☐	sneaky-penguin-121	6 months ago	-	21.0h	run 2449...	sicredi_cas.exp_nba... +1
☐	nimble-panda-307	6 months ago	-	4.1s	run 4560...	pyfunc
☐	rebellious-chimp-66	6 months ago	-	13.1h	run 2157...	sicredi_cas.exp_nba... +1
☐	nosy-penguin-34	6 months ago	-	9.1min	run 8468...	sicredi_cas.exp_nba... +1

Implantação/Deploy



Experiments > /Groups/databricks_dev_eng_rel/Experiments/PROPENSAO_AQUISICAO_CARTAO_CREDITO > Runs >

nimble-sponge-875 Send feedback

[Reproduce Run](#) [Register model](#)

[Overview](#) [Model metrics](#) [System metrics](#) [Traces](#) [Artifacts](#)

Description

No description

Metrics (5)

Search metrics			
Metric	Latest	Min	Max
calibration_auc	0.9329220094178376	0.9329220094178376	0.9329220094178376
cross_val_auc	0.9349981141617022	0.9349981141617022	0.9349981141617022
expected_prod_auc	0.7837330885293213	0.7837330885293213	0.7837330885293213
test_auc	0.9291915672967145	0.9291915672967145	0.9291915672967145
training_auc	0.9354437492984198	0.9354437492984198	0.9354437492984198

Parameters (65)

Search parameters	
Parameter	Value
mtries	-1
response_column	contratou

About this run

Created at	Dec 08, 2025, 11:18 AM
Created by	efee32b3-7259-4b01-a463-9cc0ee7ab05b
Experiment ID	4340079015511653
Status	Finished
Run ID	d873163da3944abd94be9fb25e4ce51c
Duration	1.9h
Source	run 788939504261838 of job 570754212002492
Logged models	h2o +1

Datasets

None

Tags

sp... : path=s3://sicredi-databricks-prd-group-eng...

Registered models

[sicredi_cas.exp_nba.propensao_aquisicao_cartao_credito](#) v17

Implantação/Deploy

Experiments > /Groups/databricks_dev_eng_rel/Experiments/PROPENSAO_AQUISICAO_CARTAO_CREDITO > Runs >

 nimble-sponge-875  Send feedback


 [Reproduce Run](#) [Register model](#) 

[Overview](#) [Model metrics](#) [System metrics](#) [Traces](#) [Artifacts](#)

- > capper
- ▼ model
 - > metadata
 - > model.h2o
 - MLmodel
 - conda.yaml
 - python_env.yaml
 - requirements.txt
 - confusion_matrix_F1.html
 - confusion_matrix_F2.html
 - expected_prod_distplot.png
 - expected_prod_faixa_score.html
 - expected_prod_lift.html
 - expected_prod_response_rate.html
 - feat_imp.json
 - feature_importance.html**
 - tail_limits.json
 - training_dataset_vol.html
 - training_lift.html
 - training_response_rate.html

 feature_importance.html (8.66 KB) 

Feature importance



LLM

- Do inglês “*Large Language Models*”
- “A *large language model (LLM)* is a [neural network](#) trained on a vast amount of text for [natural language processing](#) tasks, especially [language generation](#). LLMs can typically generate, summarize, translate, and analyze text in many contexts, and are a foundational technology behind modern [chatbots](#).”
([Wikipedia](#))

GenAI

- **De acordo com a [Amazon](#):** “A inteligência artificial generativa (GenAI) constitui uma modalidade de IA capaz de criar novos conteúdos e ideias, como diálogos, narrativas, imagens, vídeos e música. Ele pode aprender linguagem humana, linguagens de programação, arte, química, biologia ou qualquer assunto complexo.”
- **A principal diferença da GenAI da IA “tradicional” é que ela gera dados novos a partir de um modelo de machine learning probabilístico. A palavra “probabilística” advém do fato que a geração do modelo assume uma “probabilidade” de estar correta (Ex.: probabilidade da próxima palavra estar correta).**



GenAI

- Além disso, um modelo de GenAI pode gerar diferentes dados para o mesmo input/prompt.
- Em IA Generativa, o parâmetro de temperatura (temperature, em inglês) é uma configuração que controla o grau de aleatoriedade, criatividade e previsibilidade das respostas geradas por um modelo de inteligência artificial.

GPTs

- GPT é uma arquitetura de modelo de linguagem baseada em transformers que utiliza aprendizado de máquina para gerar texto coerente e contextualmente relevante.
- É utilizado em uma variedade de tarefas de processamento de linguagem natural e visão computacional, como tradução, resumo de e geração de texto, criação de imagens e vídeos.
- Aplicações comuns: ChatGPT, Perplexity, Gemini

Exemplo: Processo de predição de um GPT



Assistir: <https://www.youtube.com/watch?v=wjZofJX0v4M&t=1172s>

Exemplos de ferramentas de um Data Scientist

Extração de Dados e Manipulação de Dados



presto



Visualização de Dados



Modelagem



Amazon SageMaker



TensorFlow



Comunicação




Exemplos de ferramentas de um Data Scientist


Extração de Dados e Manipulação de Dados



Visualização de Dados



Modelagem



Comunicação



Ferramentas de IA Generativa

Quais termos e jargões é possível encontrar no mundo dos negócios?

Jargões de Negócio

➤ KPIs

➤ MVP


➤ Metodologia Ágil

KPIs

Indicadores-chave de desempenho

Já os **KPIs** (*Key Performance Indicators*) são um subconjunto de métricas que são mais relevantes e críticos para o sucesso da empresa em relação aos objetivos estratégicos definidos.

Os KPIs geralmente são mais específicos e devem estar alinhados com a visão e a estratégia geral da empresa.



Uma **métrica** é uma medida quantitativa que ajuda a entender o desempenho de uma empresa ou projeto.

Por exemplo, o número de visitantes do site, o tempo médio de permanência no site ou o número total de vendas concluídas podem ser considerados métricas.

Portanto, todo KPI é uma métrica, mas nem toda métrica é um KPI.

Note que KPIs são métricas de negócio e não são técnicas. Por exemplo, a medida de qualidade de um modelo de ML (como AUC) não é considerado um KPI.

MVP

- Do inglês “Minimum Viable Product” (produto mínimo viável)

Non MVP (Waterfall) Approach




MVP Agile Approach



Metodologia Ágil

- É uma abordagem de gestão de projetos baseada em ciclos iterativos, entregas contínuas e flexibilidade.
- É um conceito concebido em desenvolvimento de software.
- Pode ser adaptado para ciência de dados, porém devido à natureza mais imprevisível que é de se trabalhar com dados de negócio, é mais difícil adotar a metodologia ágil nos fluxos.



Considerações Mercado vs. Academia

Diferenças entre academia e mercado

Academia

Rigor metodológico

Publicações, teoria

Curiosidade aberta

Times pequenos de pesquisa


Mercado

Pragmatismo e velocidade

Entregas contínuas e impacto direto

Alinhamento com objetivos de negócio

Times multidisciplinares e escaláveis



Minha Experiência como Cientista de Dados no Mercado

ICMC TV
8,16 mil inscritos

Inscrição

336

Compartilhar

Perguntar

Salvar

Palestra do Rodrigo Mello da UFSCAR
disponível em
<https://www.youtube.com/watch?v=Lvt3hFQUhHY>