

MAT02053


Estatística Aplicada a Negócios

Prof. Renan Xavier Cortes

*Workflow de um problema de negócio que envolva dados:
metodologia CRISP-DM*


Processo de Negócio em Data Science

Os dados são confiáveis?
Eles estão validados?
Eles possuem características necessárias pra responder o que eu quero?



Fonte: <https://www.youtube.com/watch?v=oseHCwDBfSE&list=PLriUvS7IljvLcLnrVYUyNc9nXhiM9kWjq>


... E o processo operacional?



Fonte: Wickham, Hadley, and Garrett Grolemund. *R for data science: import, tidy, transform, visualize, and model data.* "O'Reilly Media, Inc.", 2016.

... E o processo operacional?

***"Visualizations surprises you,
but do not scale. Model
scales but do not surprises
you" - Wickham, Hadley***



CRISP-DM

- CRISP-DM (ou simplesmente CRISP) significa **Cross Industry Standard Process for Data Mining**
- “Começar um projeto de dados, às vezes é como tirar uma casquinha de um machucado... Mas quando tu começa a tirar essa casquinha vem uma sangueira...”
- *“It is tempting—but usually a mistake—to view the data mining process as a software development cycle. (...) This can be a mistake because data mining is an exploratory undertaking closer to research and development than it is to engineering. The CRISP cycle is based around exploration; it iterates on approaches and strategy rather than on software designs.” (Provost, F., & Fawcett, T. (2013))*

CRISP-DM

- *“Data scientists should review the literature to see what else has been done and how it has worked. On a larger scale, a team can invest substantially in building experimental testbeds to allow extensive agile experimentation. If you’re a software manager, this will look more like research and exploration than you’re used to, (...)” (Provost, F., & Fawcett, T. (2013))*
- A principal lição é a de que o grau de incerteza e imprevisão de projetos de dados é maior do que o normal no mundo dos negócios.

CRISP-DM




Figura do Processo CRISP-DM

Fonte: Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.

CRISP-DM

➤ A metodologia CRISP tem seis etapas:

1. Compreensão do Negócio

2. Compreensão dos Dados

3. Preparação dos Dados

4. Modelagem

5. Avaliação

6. Implantação

Esta é uma fase crítica e, às vezes, essas três etapas iniciais acontecem concomitantemente

Deploy em Produção
Monitoramento

CRISP-DM: Etapa 1 — Compreensão do Negócio

- Compreender claramente o problema de negócio é a primeira etapa essencial
- Problemas de negócio raramente chegam definidos de forma clara e objetiva
- A definição do problema e o desenho da solução são processos iterativos (em geral, com muitas reuniões)
- O sucesso de um projeto muitas vezes está em transformar o problema de negócio em problemas de ciência de dados adequados.
- Perguntas-chave:
 - O que exatamente queremos fazer?
 - Como isso será realizado na prática?
 - Que times isso impacta?
 - Como isso será utilizado?
- Nessa etapa, **até mesmo questões aparentemente banais** podem levar mais tempo do que se imagina



CRISP-DM: Etapa 1 — Compreensão do Negócio

- Exemplo: área X de um banco quer criar um modelo de Churn de clientes para aumentar a retenção.

Expectativa

Vs.

Realidade



Vamos criar a base, estimar os clientes mais propensos a sair da empresa, abordá-los e todo mundo será feliz.

O que significa “sair da empresa”?
O cliente fechar a conta corrente?
O cliente parar de transacionar durante 6 meses?
Durante 12 meses?
Que tipo de transação vamos considerar?
Vamos contabilizar clientes que tem somente conta poupança?



CRISP-DM: Etapa 2 — Compreensão dos Dados

- Raramente os dados disponíveis correspondem exatamente ao problema que se deseja resolver.
- Dados históricos geralmente foram coletados para outros objetivos, e não para o problema atual.
- Diferentes bases de dados podem conter informações distintas, como:
 - Base de clientes;
 - Base de transações;
 - Base de respostas de campanhas de marketing.
- Essas bases podem diferir quanto à cobertura, qualidade e confiabilidade.

CRISP-DM: Etapa 2 — Compreensão dos Dados

- A área de negócio responsável por aquele dado é a mais indicada para responder respostas acerca daquele dado, principalmente **quais tabelas mais confiáveis para se consultar (lembrem da “camada de ouro” de um Data Lake?)**.
- Uma etapa importante é avaliar o custo-benefício de cada fonte de dados antes de investir em sua obtenção.
- À medida que os dados são analisados, a abordagem do projeto pode mudar.

CRISP-DM: Etapa 2 — Compreensão dos Dados

Problemas aparentemente semelhantes podem exigir abordagens completamente diferentes

Exemplo: Fraude em Cartão de Crédito

- As transações fraudulentas normalmente são identificadas posteriormente.
- Existe um **histórico confiável** indicando quais transações são fraude e quais são legítimas.



Exemplo: Fraude no Sistema de Saúde (SUS)

- Os fraudadores também são usuários legítimos do sistema.
- **Não existe uma variável confiável** indicando quais registros são fraudulentos.
- Nesse cenário, **o aprendizado supervisionado não é adequado.**
- A solução normalmente utiliza técnicas **não supervisionadas**, como:
 - Perfilamento (Profiling);
 - Clusterização;
 - Detecção de anomalias.



CRISP-DM: Etapa 2 — Compreensão dos Dados

- Uma pergunta de suma importância:

Os dados necessários para responder a essa pergunta existem???

Exemplos:

- A área de CRM (*Customer Relationship Management*) de um banco gostaria de encontrar clientes que “desmarcaram” a opção de receber notificações. No entanto, o time de dados não encontra no datalake essa informação, pois não é trackeada no aplicativo (este que, por sua vez, possui diferentes versões e sem padrão entre as versões).
- Uma mineradora está interessado na vazão da britagem de pedras nas esteiras, mas não possui a informação de qual caminhão fez o descarregamento dentre duas opções de esteira.
- Queremos entender quais clientes estão retirando senha nas agências bancárias. O sistema não é integrado e não temos esse dado.


CRISP-DM: Etapa 3 — Preparação dos Dados

- **Integrar diferentes bases de dados pode ser um desafio**, exigindo limpeza, padronização e associação correta dos registros.
- **Problemas como duplicidade e inconsistência de registros de clientes são comuns** e frequentemente exigem técnicas analíticas específicas.
- **A preparação dos dados ocorre em paralelo ao entendimento dos dados (“learn by doing”)**
- **Principais atividades da preparação dos dados:**
 - Contemplar regras de negócio.
 - Integrar múltiplas fontes de dados.
 - Converter dados para formato tabular.
 - Tratar valores ausentes (remoção ou imputação).
 - Converter tipos de dados (texto, categorias e números).
 - Transformar variáveis categóricas quando necessário.
 - Normalizar ou padronizar variáveis numéricas para torná-las comparáveis.
 - Adequar os dados às exigências da técnica analítica que será utilizada.
 - Tratar datas.



CRISP-DM: Etapa 3 — Preparação dos Dados


- Por exemplo, montar um base para um modelo de Churn NÃO é uma tarefa tão trivial assim



CRISP-DM: Etapa 3 — Preparação dos Dados

- Por exemplo, montar um base para um modelo de Churn NÃO é uma tarefa tão trivial assim


Churn Data Leak Example



Fonte: <https://zyabkina.com/how-to-predict-churn/>

CRISP-DM: Etapa 3 — Preparação dos Dados

➤ Muitas vezes as bases possuem problemas



CRISP-DM: Etapa 3 — Preparação dos Dados

- Nesta etapa, em geral, muitas análises descritivas são realizadas a fim de compreender o fenômeno em estudo.
- Caso o projeto envolva um modelo de machine learning supervisionado, é comum realizar uma análise descritiva univariada de cada covariável com a variável resposta a fim de identificar poder discriminatório individual (ver código `funcoes_plot.R`)
- Estabilidade temporal das variáveis envolvidas também é importante garantir nesse processo.

CRISP-DM: Etapa 4 — Modelagem

- Na etapa anterior (Preparação dos Dados), algumas precauções já devem ser levadas em consideração para a modelagem como:
 - Engenharia de Features
 - Evitar Data Leakage
- Engenharia de Features: etapa de criação de novas variáveis potenciais para a modelagem. Por exemplo, o “Tempo de Conta” de um cliente de banco exige ser criada caso você tenha acesso somente à variável “Data de Criação de Conta”.
- Data Leakage: quando uma variável contém informações que **não estariam disponíveis no momento da tomada de decisão**, mas aparecem nos dados históricos. Isto, superestima-se artificialmente a capacidade preditiva do modelo.

CRISP-DM: Etapa 4 — Modelagem

- A Modelagem, em si, é o momento que o (a) Cientista de Dados tem (e faz sentido ter) o **maior grau de autonomia** nesse processo.
- Ele (a) que possui experiência e conhecimento para decidir algoritmos, pacotes, métricas de qualidade do modelo, técnicas estatísticas, etc. a fim de extrair um modelo que vai responder da melhor maneira o problema de negócio.




CRISP-DM: Etapa 5 — Avaliação

- Checar se o modelo estimado atende ao problema de negócio.
- Caso explicabilidade seja um ponto importante, ele é explicável? Ele é estável?
- Tem muito falso positivo?
- Caso a predição tenha que ser dicotomizada, qual o threshold de probabilidade? (Ex.: um time de seguros que enviar comunicação apenas para clientes com altíssima probabilidade de contratar (alta especificidade). No entanto, o time de CRM é quem gerencia essas comunicações e caso essa lista de clientes seja muito pequena, esses clientes nunca receberão nenhuma comunicação, pois outras comunicações já são enviadas para eles).
- Busque feedback de outros (as) colegas/stakeholders e esteja aberto à sugestões de melhorias


CRISP-DM: Etapa 5 — Avaliação

- Será feito um teste A/B com esse modelo para compará-lo com algum benchmark/modelo atual? (Kohavi, Ron & Tang, Diane & Xu, Ya. (2020). Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing. 10.1017/9781108653985.)



- A linguagem que foi feita o modelo pode ser usada ou temos que adaptar? (Ex.: reg. logística hardcodeada em linguagem JAVA, pois o motor de decisão está nessa linguagem)
- Se for o caso, o modelo é “auditável”? (Ex.: modelo de concessão de crédito pode ser auditado pelo Banco Central)
- Filosofia “Feito é melhor que perfeito” que ilustra que achamos que vamos encontrar um modelo perfeito. Uma hora temos que “bater o martelo”.
- Busque feedback de outros (as) colegas/stakeholders e esteja aberto à sugestões de melhorias.

CRISP-DM: Etapa 6.1 — Implantação/Deploy em Produção



CRISP-DM: Etapa 6.1 — Implantação/Deploy em Produção


- Um modelo pode ser exposto de maneira assíncrona (em Batch/offline) ou síncrona (online) .
- Nesta etapa, provavelmente terá atuação de outras equipes de MLOps, DevOps, Engenheiros de Dados para auxiliar na implantação ou pipeline de geração dos dados.
- Ferramentas potenciais: MLFlow, Amazon Sagemaker, etc.

CRISP-DM: Etapa 6.2 — Monitoramento

- Estrutura-se uma forma de monitorar os resultados do modelo.
- Se o seu plano de ação visa melhorar um indicador/KPI, é interessante criar um acompanhamento automático em um Dashboard, com indicação clara do momento em que o plano de ação foi implantado.
- Crie um Dashboard de acompanhamento do modelo e atualize a documentação. Métricas de monitoramento comuns:
 - KS/AUC
 - Distribuição dos scores/clusters
 - Taxa do Target.

CRISP-DM: Etapa 6.2 — Monitoramento

- Insira também os gatilhos propostos para iniciar um processo de retreino ou calibragem do modelo.
- Monitoramento do Data Drift de covariáveis também é importante.




Isso afeta as previsões do modelo!!!

A área responsável por essa variável mudou a metodologia de cálculo (Ex.: passou a considerar TED além do PIX em um perfil transacional)

CRISP-DM: Etapa 6.2 — Monitoramento

- Se o modelo estiver sendo implementado somente em parte dos dados via Teste A/B (Ex.: Grupo Controle vs. Grupo Tratamento) deve-se acompanhar a métrica de ambos os grupos.

Plano de Ação	Revisão da política de Horas Extras
Por que?	Colaboradores que fazem hora extra têm probabilidade de 31% de turnover.
O que foi feito?	Criação de grupo controle e teste de pessoas que podem fazer hora extra e não podem.
KPI em acompanhamento	Percentual de Turnover (% de colaboradores que deixaram a empresa)




	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6	Mês 7	Mês 8	Mês 9	Mês 10	Mês 11	Mês 12
% do Grupo Teste (grupo com aplicação da mudança)	30%	45%	60%	75%	90%	100%	100%	100%	100%	100%	100%	100%
% do Grupo Controle	70%	55%	40%	25%	10%	0%	0%	0%	0%	0%	0%	0%
KPI do Grupo de Teste	9,8%	10,1%	9,0%	9,4%	10,2%	10,0%	9,2%	9,3%	10,6%	10,3%	9,1%	9,1%
KPI do Grupo Controle	45,4%	47,2%	47,8%	43,7%	45,7%							
KPI Geral	34,7%	30,5%	24,5%	18,0%	13,8%	10,0%	9,2%	9,3%	10,6%	10,3%	9,1%	9,0%

CRISP-DM: Etapa 6.2 — Monitoramento

- Se o modelo estiver sendo implementado somente em parte dos dados via Teste A/B (Ex.: Grupo Controle vs. Grupo Tratamento) deve-se acompanhar a métrica de ambos os grupos.

Teste A/B



90% priorizado: Lista de proposições ranqueada com os modelos


10% aleatório: Lista de proposições "embaralhada"

$$\text{Taxa de conversão} = \frac{\text{Conversões}}{\text{Envios}}$$

De junho até agosto a taxa de conversão dos estímulos que foram priorizados foi **1.26x** maior do que os aleatórios

Conversões

Quantidade de conversões por dia pela quantidade de envios por dia



➤ **Sugestão de material complementar presente no Moodle da Disciplina.**