

MAT02053

Estatística Aplicada a Negócios

Prof. Renan Xavier Cortes

Desafios de criação de bases de dados do ponto de vista operacional

Cronograma

- **Obtenção de Dados**
- **Joins**
- **Limpeza de Dados**
- **Manipulação de Dados**
- **Data Leakage**

Obtenção de Dados

➤ Como se conectar a múltiplas fontes de dados?



Obtenção de Dados

- No ambiente corporativo, é muito comum trabalharmos remotamente. Isto é, trabalhar na nuvem conectando-se remotamente à dados que estão hospedados fora da sua máquina. Exemplo:

*Ver código de
conexão*

```
library(DBI)
library(RPostgres)

conn <- dbConnect(
  RPostgres::Postgres(),
  host = "ep-twilight-frost-athewr88-pooler.c-9.us-east-1.aws.neon.tech",
  port = 5432,
  dbname = "neondb",
  user = "neondb_owner",
  password = "my_password",
  sslmode = "require",
  channel_binding = "require"
)

> lazy_persons <- tbl(conn, "persons")
> head(lazy_persons)
# A query: ?? x 5
# Database: postgres [neondb_owner@ep-twilight-frost-athewr88-pooler.c-9.us-east-1.aws.neon.tech:5432/neondb]
   id first_name last_name date_of_birth email
<int> <chr>      <chr>      <date>    <chr>
1     1 John      Doe        1995-01-05 john.doe@postgresqltutorial.com
2     2 Jane      Doe        1995-02-05 jane.doe@postgresqltutorial.com
```

Exercício pra casa:
puxar dados de alguma
base de dados pública

Joins

- Uma das tarefas **MAIS COMUNS** e **IMPRESINDÍVEIS** para quem trabalha com dados é efetivamente saber **combinar** informações de múltiplas tabelas.
- Suponha que você um (a) cientista de dados de um supermercado e precisa calcular os preços com desconto que são aplicados por tipo de produto.

**Tabela
Produtos**

ID Produto	Descrição Produto	Valor (R\$)	Tipo
1	Carne Bovina Alcatra	68,9	Açougue
2	Peito de Frango	24,5	Açougue
3	Refrigerante 2 L	8,99	Bebidas
4	Maçã Gala 1 kg	9,8	Hortifruti
5	Leite Integral 1 L	5,99	Laticínios
6	Queijo Mussarela	42,5	Laticínios
7	Manteiga	10,5	Laticínios
8	Detergente Líquido	3,49	Limpeza
9	Sabão em Pó	24,9	Limpeza
10	Amaciante	20,3	Limpeza
11	Arroz 5 kg	32,9	Mercearia
12	Pão Francês	12,5	Padaria
13	Bolo de Chocolate	29,9	Padaria
14	Camiseta Básica	39,9	Roupas


Tipo	Alíquota de Desconto (%)
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18

**Tabela
Descontos
por Tipo**

Joins

➤ Passo 1: associar cada produto com sua respectiva alíquota:

ID Produto	Descrição Produto	Valor (R\$)	Tipo	Alíquota
1	Carne Bovina Alcatra	68,9	Açougue	8
2	Peito de Frango	24,5	Açougue	8
3	Refrigerante 2 L	8,99	Bebidas	?
4	Maçã Gala 1 kg	9,8	Hortifruti	?
5	Leite Integral 1 L	5,99	Laticínios	5
6	Queijo Mussarela	42,5	Laticínios	5
7	Manteiga	10,5	Laticínios	5
8	Detergente Líquido	3,49	Limpeza	15
9	Sabão em Pó	24,9	Limpeza	15
10	Amaciante	20,3	Limpeza	15
11	Arroz 5 kg	32,9	Mercearia	?
12	Pão Francês	12,5	Padaria	10
13	Bolo de Chocolate	29,9	Padaria	10
14	Camiseta Básica	39,9	Roupas	20




Tipo	Alíquota
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínio	5
Higiene	12
Congela	18

➤ Passo 2: calcular o valor com desconto.


Obs.: o Passo 1 também seria possível resolver isso usando a função PROCV do Excel, mas ela é limitada

Joins


- O Passo 1 é um típico problema para ser resolvido via JOIN.
- Suponha que você tenha tabela A e uma tabela B, os principais tipos de JOIN são:




Left Join




Inner Join



Anti Join



Full Join



Right Join

Joins

- **CHAVE:** variável (eis) presente (s) em ambas as tabelas


A variável Tipo é a variável chave que conecta as duas tabelas!

ID Produto	Descrição Produto	Valor (R\$)	Tipo
1	Carne Bovina Alcatra	68,9	Açougue
2	Peito de Frango	24,5	Açougue
3	Refrigerante 2 L	8,99	Bebidas
4	Maçã Gala 1 kg	9,8	Hortifruti
5	Leite Integral 1 L	5,99	Laticínios
6	Queijo Mussarela	42,5	Laticínios
7	Manteiga	10,5	Laticínios
8	Detergente Líquido	3,49	Limpeza
9	Sabão em Pó	24,9	Limpeza
10	Amaciante	20,3	Limpeza
11	Arroz 5 kg	32,9	Mercearia
12	Pão Francês	12,5	Padaria
13	Bolo de Chocolate	29,9	Padaria
14	Camiseta Básica	39,9	Roupas

Tipo	Alíquota de Desconto (%)
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18

Joins

- Exemplo de LEFT JOIN: mantém as linhas da tabela da direita, adicionando a coluna de desconto quando existir correspondência.




ID Produto	Descrição Produto	Valor (R\$)	Tipo	Alíquota
1	Carne Bovina Alcatra	68,9	Açougue	8
2	Peito de Frango	24,5	Açougue	8
3	Refrigerante 2 L	8,99	Bebidas	?
4	Maçã Gala 1 kg	9,8	Hortifruti	?
5	Leite Integral 1 L	5,99	Laticínios	5
6	Queijo Mussarela	42,5	Laticínios	5
7	Manteiga	10,5	Laticínios	5
8	Detergente Líquido	3,49	Limpeza	15
9	Sabão em Pó	24,9	Limpeza	15
10	Amaciante	20,3	Limpeza	15
11	Arroz 5 kg	32,9	Mercearia	?
12	Pão Francês	12,5	Padaria	10
13	Bolo de Chocolate	29,9	Padaria	10
14	Camiseta Básica	39,9	Roupas	20

Tipo	Alíquota
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18

Joins

- Exemplo de INNER JOIN: retorna apenas os produtos cujo tipo existe nas duas tabelas, adicionando a coluna de desconto




Note que os produtos 3,4 e 11 não aparecem!

ID	Descrição Produto	Valor	Tipo	Alíquota
1	Carne Bovina	68,9	Açougue	8
2	Peito de Frango	24,5	Açougue	8
5	Leite Integral 1 L	5,99	Laticínios	5
6	Queijo Mussarela	42,5	Laticínios	5
7	Manteiga	10,5	Laticínios	5
8	Detergente Líquido	3,49	Limpeza	15
9	Sabão em Pó	24,9	Limpeza	15
10	Amaciante	20,3	Limpeza	15
12	Pão Francês	12,5	Padaria	10
13	Bolo de Chocolate	29,9	Padaria	10
14	Camiseta Básica	39,9	Roupas	20

Tipo	Alíquota
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18

Joins


- Exemplo de ANTI JOIN: retorna apenas os produtos cujo tipo não possui correspondência na tabela de descontos.



Agora só
aparecem os
produtos 3,4
e 11!


ID	Descrição Produto	Valor	Tipo	Alíquota
3	Refrigerante 2 L	8,99	Bebidas	?
4	Maçã Gala 1 kg	9,8	Hortifruti	?
11	Arroz 5 kg	32,9	Mercearia	?

Tipo	Alíquota
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18



Joins

- Exemplo de FULL JOIN: retorna todos os registros de ambas as tabelas.



Aparecem
todos os
produtos...

... e também
todos os
tipos!

ID	Descrição Produto	Valor	Tipo	Alíquota
1	Carne Bovina Alcatra	68,9	Açougue	8
2	Peito de Frango	24,5	Açougue	8
3	Refrigerante 2 L	8,99	Bebidas	?
4	Maçã Gala 1 kg	9,8	Hortifruti	?
5	Leite Integral 1 L	5,99	Laticínios	5
6	Queijo Mussarela	42,5	Laticínios	5
7	Manteiga	10,5	Laticínios	5
8	Detergente Líquido	3,49	Limpeza	15
9	Sabão em Pó	24,9	Limpeza	15
10	Amaciante	20,3	Limpeza	15
11	Arroz 5 kg	32,9	Mercearia	?
12	Pão Francês	12,5	Padaria	10
13	Bolo de Chocolate	29,9	Padaria	10
14	Camiseta Básica	39,9	Roupas	20
?	?	?	Higiene	12
?	?	?	Congelados	18

Tipo	Alíquota
Limpeza	15
Açougue	8
Padaria	10
Roupas	20
Laticínios	5
Higiene	12
Congelados	18

Joins

- Porque não usar um “PROCV” do excel?
- Motivo 1: Mantém as colunas de todas as tabelas.

ID	Descrição Produto	Valor	Tipo
1	Carne Bovina Alcatra	68,9	Açougue
2	Peito de Frango	24,5	Açougue
3	Refrigerante 2 L	8,99	Bebidas
4	Maçã Gala 1 kg	9,8	Hortifruti
5	Leite Integral 1 L	5,99	Laticínios
6	Queijo Mussarela	42,5	Laticínios
7	Manteiga	10,5	Laticínios
8	Detergente Líquido	3,49	Limpeza
9	Sabão em Pó	24,9	Limpeza
10	Amaciante	20,3	Limpeza
11	Arroz 5 kg	32,9	Mercearia
12	Pão Francês	12,5	Padaria
13	Bolo de Chocolate	29,9	Padaria
14	Camiseta Básica	39,9	Roupas

Tipo	Categoria	Alíquota
Limpeza	Não Alimentício	15
Açougue	Alimentício	8
Padaria	Alimentício	10
Roupas	Não Alimentício	20
Laticínios	Alimentício	5
Higiene	Não Alimentício	12
Congelados	Alimentício	18

ID	Descrição Produto	Valor	Tipo	Categoria	Alíquota
1	Carne Bovina Alcatra	68,9	Açougue	Alimentício	8
2	Peito de Frango	24,5	Açougue	Alimentício	8
5	Leite Integral 1 L	5,99	Laticínio	Alimentício	5
6	Queijo Mussarela	42,5	Laticínio	Alimentício	5
7	Manteiga	10,5	Laticínio	Alimentício	5
8	Detergente Líquido	3,49	Limpeza	Não Alimentício	15
9	Sabão em Pó	24,9	Limpeza	Não Alimentício	15
10	Amaciante	20,3	Limpeza	Não Alimentício	15
12	Pão Francês	12,5	Padaria	Alimentício	10
13	Bolo de Chocolate	29,9	Padaria	Alimentício	10
14	Camiseta Básica	39,9	Roupas	Não Alimentício	20




Ex.: Depois de aplicar um INNER JOIN

Joins

- Porque não usar um “PROCV” do excel?
- Motivo 2: É possível conectar tabelas com mais de uma chave.
- Ex.: suponha que as alíquotas são diferentes por cidade. Logo, a chave será Tipo + Cidade

ID	Descrição Produto	Valor	Tipo	Cidade
1	Carne Bovina Alcatra	68,90	Açougue	Porto Alegre
2	Peito de Frango	24,50	Açougue	Porto Alegre
3	Refrigerante 2 L	8,99	Bebidas	Porto Alegre
4	Maçã Gala 1 kg	9,80	Hortifruti	Porto Alegre
5	Leite Integral 1 L	5,99	Laticínios	Porto Alegre
6	Queijo Mussarela	42,50	Laticínios	Porto Alegre
7	Manteiga	10,50	Laticínios	Porto Alegre
8	Detergente Líquido	3,49	Limpeza	Porto Alegre
9	Sabão em Pó	24,90	Limpeza	Porto Alegre
10	Amaciante	20,30	Limpeza	Porto Alegre
11	Arroz 5 kg	32,90	Mercearia	Porto Alegre
12	Pão Francês	12,50	Padaria	Porto Alegre
13	Bolo de Chocolate	29,90	Padaria	Porto Alegre
14	Camiseta Básica	39,90	Roupas	Porto Alegre
1	Carne Bovina Alcatra	71,54	Açougue	Santa Maria
2	Peito de Frango	29,30	Açougue	Santa Maria
3	Refrigerante 2 L	13,18	Bebidas	Santa Maria
4	Maçã Gala 1 kg	10,78	Hortifruti	Santa Maria
5	Leite Integral 1 L	11,18	Laticínios	Santa Maria
6	Queijo Mussarela	47,74	Laticínios	Santa Maria
7	Manteiga	16,73	Laticínios	Santa Maria
8	Detergente Líquido	7,31	Limpeza	Santa Maria
9	Sabão em Pó	30,26	Limpeza	Santa Maria
10	Amaciante	24,40	Limpeza	Santa Maria
11	Arroz 5 kg	33,12	Mercearia	Santa Maria
12	Pão Francês	17,43	Padaria	Santa Maria
13	Bolo de Chocolate	33,08	Padaria	Santa Maria
14	Camiseta Básica	42,80	Roupas	Santa Maria

Tipo	Cidade	Alíquota
Limpeza	Porto Alegre	15
Açougue	Porto Alegre	8
Padaria	Porto Alegre	10
Roupas	Porto Alegre	20
Laticínios	Porto Alegre	5
Higiene	Porto Alegre	12
Congelados	Porto Alegre	18
Limpeza	Santa Maria	12
Açougue	Santa Maria	10
Padaria	Santa Maria	11
Roupas	Santa Maria	21
Laticínios	Santa Maria	6
Higiene	Santa Maria	12
Congelados	Santa Maria	20



ID	Descrição	Valor	Tipo	Cidade	Alíquota
1	Carne Bovina	68,90	Açougue	Porto Alegre	8
2	Peito de	24,50	Açougue	Porto Alegre	8
3	Refrigerante 2	8,99	Bebidas	Porto Alegre	?
4	Maçã Gala 1	9,80	Hortifruti	Porto Alegre	?
5	Leite Integral 1	5,99	Laticínios	Porto Alegre	5
6	Queijo	42,50	Laticínios	Porto Alegre	5
7	Manteiga	10,50	Laticínios	Porto Alegre	5
8	Detergente	3,49	Limpeza	Porto Alegre	15
9	Sabão em Pó	24,90	Limpeza	Porto Alegre	15
10	Amaciante	20,30	Limpeza	Porto Alegre	15
11	Arroz 5 kg	32,90	Mercearia	Porto Alegre	?
12	Pão Francês	12,50	Padaria	Porto Alegre	10
13	Bolo de	29,90	Padaria	Porto Alegre	10
14	Camiseta	39,90	Roupas	Porto Alegre	20
1	Carne Bovina	71,54	Açougue	Santa Maria	10
2	Peito de	29,30	Açougue	Santa Maria	10
3	Refrigerante 2	13,18	Bebidas	Santa Maria	?
4	Maçã Gala 1	10,78	Hortifruti	Santa Maria	?
5	Leite Integral 1	11,18	Laticínios	Santa Maria	6
6	Queijo	47,74	Laticínios	Santa Maria	6
7	Manteiga	16,73	Laticínios	Santa Maria	6
8	Detergente	7,31	Limpeza	Santa Maria	12
9	Sabão em Pó	30,26	Limpeza	Santa Maria	12
10	Amaciante	24,40	Limpeza	Santa Maria	12
11	Arroz 5 kg	33,12	Mercearia	Santa Maria	?
12	Pão Francês	17,43	Padaria	Santa Maria	11
13	Bolo de	33,08	Padaria	Santa Maria	11
14	Camiseta	42,80	Roupas	Santa Maria	21

Limpeza de Dados

- Data cleaning (limpeza de dados) é o processo de identificar e corrigir ou remover erros, inconsistências, duplicatas e dados irrelevantes de um conjunto de dados brutos.



Limpeza de Dados

➤ Exemplo de base problemática

Primeiro Nome!!!	Último Nome	ID..Funcionario	DATA ADMISSAO	ColunaAtivo	SALARIO	
João	Silva	101	2021-01-15	SIM	5000	NA
Maria	Santos	102	44211	SIM	6000	NA
J0ão	silva	101	2021-01-15	SIM	5000	NA
NA	NA	NA	NA	NA	NA	NA
Roberto	Souza	103	2023-05-11	SIM	7500	NA
NA	NA	NA	NA	NA	NA	NA
Alice	Oliveira	104	45123	SIM	800000	NA
Carlos	Pereira	105	2025-08-20	SIM	-4500	NA

Limpeza de Dados

➤ Exemplo de base problemática

Primeiro Nome!!!	Último Nome	ID..Funcionario	DATA ADMISSAO	ColunaAtivo	SALARIO	
João	Silva	101	2021-01-15	SIM	5000	NA
Maria	Santos	102	44211	SIM	6000	NA
J0ão	silva	101	2021-01-15	SIM	5000	NA
NA	NA	NA	NA	NA	NA	NA
Roberto	Souza	103	2023-05-11	SIM	7500	NA
NA	NA	NA	NA	NA	NA	NA
Alice	Oliveira	104	45123	SIM	800000	NA
Carlos	Pereira	105	2025-08-20	SIM	-4500	NA

Problemas:

- ✓ Problemas Estruturais (Nomes de Colunas)
- ✓ Coluna “Fantasma” e Coluna Constante
- ✓ Problemas de Linhas e Dados Ausentes (NAs)
- ✓ Erros de Digitação (Ex.: “JOão” e “João” e “Maria “)
- ✓ Inconsistência de Tipos de Dados (Datas)
- ✓ Valores Discrepantes (Outliers) e Erros Numéricos (Salário Negativo?)
- ✓ Dados Duplicados

Aqui tem um espaço invisível pois está escrito “Maria “ ao invés de “Maria”

Limpeza de Dados

➤ Base após a limpeza

primeiro_nome	ultimo_nome	id_funcionario	data_admissao	salario
João	Silva	101	2021-01-15	5000
Maria	Santos	102	2021-01-15	6000
Roberto	Souza	103	2023-05-11	7500
Alice	Oliveira	104	2023-07-16	8000
Carlos	Pereira	105	2025-08-20	NA

*Ver código de
data cleaning*

Manipulação de Dados

- Neste caso, “Manipulação” de Dados é no sentido de lidar/manejar/preparar os dados.
- Também conhecido como “Data Wrangling”



Manipulação de Dados

- A família de JOINS vista anteriormente, também pode ser vista como uma etapa de um processo de manipulação de dados.
- Mas manipulação é mais do que isso: *“Data wrangling is the process of cleaning, structuring and enriching raw data to be used in [data science](#), [machine learning](#) (ML) and other data-driven applications”*

(IBM)



Manipulação de Dados

➤ Suponha que você tenha três bases:

Tabela vendas

id_venda	id_cliente	id_produto	data_hora
1	101	1	2025-01-05 09:15:23
2	102	2	2025-01-09 14:32:10
3	103	3	2025-01-15 18:05:41
4	104	4	2025-01-20 11:48:17
5	105	5	2025-01-28 20:13:55
6	101	2	2025-02-03 08:20:44
7	102	1	2025-02-10 15:55:01
8	106	6	2025-02-18 17:43:26
9	107	3	2025-02-22 10:12:39
10	103	5	2025-02-27 19:30:58
11	108	4	2025-03-05 13:45:11
12	109	2	NA
13	101	1	2025-03-14 09:01:37
14	110	6	2025-03-21 16:28:45
15	104	3	2025-03-30 12:17:09
16	102	5	2025-04-04 18:50:23
17	103	4	2025-04-12 11:33:52
18	105	2	2025-04-19 15:04:18
19	106	1	2025-04-25 08:57:40
20	101	6	2025-04-28 21:10:05
21	107	3	2025-05-06 14:22:34
22	108	5	2025-05-13 10:41:56
23	109	2	2025-05-18 17:19:42
24	110	4	2025-05-24 09:36:27
25	104	1	2025-05-30 19:48:13
26	105	6	2025-06-05 07:55:49
27	102	3	2025-06-11 13:27:18
28	101	5	2025-06-18 16:42:31
29	106	2	NA
30	103	4	2025-06-30 20:05:54
30	103	4	2025-06-30 20:05:54

Tabela clientes

id_cliente	nome	cidade
101	Ana	Porto Alegre — RS
102	Bruno	Curitiba — PR
103	Carlos	Campinas — SP
104	Diana	Porto Alegre — RS
105	Eduardo	Curitiba — PR
106	Fernanda	Londrina — PR
107	Gabriel	Campinas — SP
108	Helena	Porto Alegre — RS
109	Igor	Curitiba — PR
110	Juliana	Porto Alegre — RS

Tabela produtos

id_produto	produto	categoria	preco
1	Arroz 5 kg	Alimentos	28.90
2	Refrigerante 2 L	Bebidas	9.50
3	Detergente	Limpeza	4.90
4	Shampoo	Higiene	18.90
5	Cafe 500 g	Alimentos	21.50
6	Sabao em Po	Limpeza	16.90

Tarefa 1: crie uma tabela com os nomes dos clientes de Porto Alegre para os meses de Março, Abril, Maio e Junho com quantidade de vendas e faturamento (R\$) por categoria

Ver código de data wrangling

Manipulação de Dados

➤ Resposta da Tarefa 1:

cliente	mes	categoria	vendas	faturamento
<chr>	<dbl>	<chr>	<int>	<dbl>
Ana	3	Alimentos	1	28.9
Ana	4	Limpeza	1	16.9
Ana	6	Alimentos	1	21.5
Diana	3	Limpeza	1	4.9
Diana	5	Alimentos	1	28.9
Helena	3	Higiene	1	18.9
Helena	5	Alimentos	1	21.5
Juliana	3	Limpeza	1	16.9
Juliana	5	Higiene	1	18.9

Tarefa 2: reorganize essa tabela resultante da Tarefa 1 para apresentar os valores do faturamento das categorias em colunas (valores com combinações ausentes, preencha com zero)

Manipulação de Dados


➤ Resposta da Tarefa 2:

cliente	mes	Alimentos	Limpeza	Higiene
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
Ana	3	28.9	0	0
Ana	4	0	16.9	0
Ana	6	21.5	0	0
Diana	3	0	4.9	0
Diana	5	28.9	0	0
Helena	3	0	0	18.9
Helena	5	21.5	0	0
Juliana	3	0	16.9	0
Juliana	5	0	0	18.9

Tarefa 3: com os dados originais, faça um gráfico de gastos totais por cliente e período do dia e responda: “Qual cliente que mais gastou em valores absolutos pelo período da noite?”


Manipulação de Dados

➤ Resposta da Tarefa 3:



Data Leakage

- **Data Leakage:** quando uma variável contém informações que **não estariam disponíveis no momento da tomada de decisão**, mas aparecem nos dados históricos. Isto, superestima-se artificialmente a capacidade preditiva do modelo.



Data Leakage

- Data Leakage pode estar presente também nas etapas de pré-processamento de dados nas divisões entre treino e teste para validação de modelos de ML.
- Exemplo imputação de média: você não pode usar os dados de teste para descobrir qual média imputar nos valores faltantes.



Tudo o que eu “aprendi” aqui...

... deve ser aplicado aqui.

Ou seja, eu não posso “aprender” aqui o valor da média a ser imputado

Data Leakage

➤ Exemplo: Prever a aprovação em uma disciplina

Objetivo: prever se um aluno será aprovado antes do final do semestre.



Frequência (%)	Nota Parcial	Horas de Estudo	Nota Final	Aprovado
92	7,5	35	8,4	Sim
81	6,2	28	6,8	Sim
68	4,8	18	5,1	Não
54	2,7	10	3,0	Não
96	8,1	42	9,2	Sim

O erro: Usar **Nota Final** como variável preditora.

O modelo rapidamente aprende uma regra praticamente perfeita:

Se Nota Final $\geq 6,0$, então Aprovado = Sim.

Data Leakage

- **Exemplo: Concessão de empréstimo**
- **Objetivo:** prever se um cliente será inadimplente.

Variáveis utilizadas:

- renda
- idade
- valor solicitado
- score de crédito
- número de dependentes
- **quantidade de parcelas atrasadas (???)**



O modelo acaba aprendendo uma coisa óbvia: quem atrasou parcelas vira inadimplente. Mas isso é uma consequência da inadimplência, não uma causa.

Data Leakage

➤ Exemplo: Fraude

➤ Objetivo: Prever se uma transação é fraudulenta.

Variáveis Utilizadas:

- Valor
- País
- Horário
- Transação estornada



➤ Problema: Uma transação normalmente é estornada justamente porque foi identificada como fraude.

O modelo aprende:

Transação estornada = fraude

Em produção essa informação não existe.

Data Leakage

➤ Exemplo: Séries Temporais

Em problemas temporais, a ordem cronológica deve ser respeitada para evitar que o modelo aprenda com informações futuras.

